

Alfabetização no Brasil

Relatório de análise e modelagem

Ana Carolina Perchak dos Santos


Avaliações de 2023 e 2024. Indicadores socioeconômicos de 2010.

O estudo descreve diferenças de contexto e avalia os limites da previsão individual. O resultado do teste recomenda cautela: o modelo sinaliza 80,0% dos alunos e tem F1 de 0,5800, próximo da referência que sinaliza todos.

ALFABETIZAÇÃO NO BRASIL

Distribuição da alfabetização

Amostra de treino • 2023 • 122.978 alunos com avaliação válida



Fonte: avaliações de alfabetização do Inep, via Base dos Dados.
Percentuais não ponderados da amostra de treino; não representam estimativas oficiais.

Acesso à apresentação e aos materiais

Vídeo da apresentação (pasta no Drive)

Materiais e backups no Google Drive

Repositório no GitHub

Objetivo

Analisar diferenças na alfabetização infantil e avaliar se informações educacionais, territoriais e socioeconômicas permitem prever a classificação de alunos do 2º ano do Ensino Fundamental.

O projeto reúne preparação de dados, análise exploratória e comparação de modelos supervisionados, com foco no apoio à análise de políticas públicas educacionais.

1. Entendimento do negócio

Problema de negócio

Gestores públicos precisam acompanhar os resultados de alfabetização, identificar desigualdades e avaliar o cumprimento das metas educacionais. Além de descrever o cenário, é importante verificar até que ponto os dados disponíveis permitem antecipar dificuldades de aprendizagem.

Por que analisar a alfabetização?

A alfabetização nos primeiros anos é uma etapa essencial da trajetória escolar. Sua análise pode apoiar o acompanhamento das redes de ensino e orientar investigações sobre diferenças entre territórios.

Quem pode utilizar a análise?

Gestão educacional: acompanhamento dos resultados e das metas.

Secretarias de Educação: investigação de diferenças entre municípios e redes.

Equipes de dados: avaliação da qualidade das bases e dos limites dos modelos.

Insight: diferenças territoriais ajudam a entender o contexto educacional, mas não explicam, sozinhas, a situação de cada aluno.

2. Definição da variável-alvo

Qual resultado o modelo procura prever?

A coluna alfabetizado, com os códigos da fonte:

0: não alfabetizado.

1: alfabetizado.

Entre as avaliações válidas, a classificação foi conferida com a proficiência: valores abaixo de 743 correspondem à classe 0; valores a partir de 743, à classe 1.

Quais alunos entram na modelagem?

Alunos do 2º ano com presença registrada, prova preenchida, proficiência disponível e classificação válida.

Registros sem avaliação válida permanecem na base bruta, mas não são usados como exemplos de não alfabetização. O desempenho do modelo não demonstra sua capacidade de prever o resultado dos alunos ausentes.

Como foi evitado o vazamento da resposta?

A proficiência não entra como preditor, pois determina diretamente a classificação. Presença, preenchimento, identificadores, resultados agregados do mesmo ano e metas também ficam fora das variáveis de entrada.

3. Base de dados

Fonte	Informações utilizadas	Referência
Avaliação da Alfabetização — Inep, via Base dos Dados	Alunos, resultados municipais e estaduais, metas e dicionário	Avaliações de 2023 e 2024; referências das metas preservadas
Diretórios Brasileiros — Base dos Dados	Código e nome do município, UF e região	Diretório disponível na extração
Atlas do Desenvolvimento Humano — via Base dos Dados	População, IDHM, renda, analfabetismo adulto e saneamento	2010

Amostra utilizada

A seleção usa um hash de ano, município, escola e aluno para extrair aproximadamente 10% dos registros. O resultado da avaliação não participa da seleção. A reprodução da amostra depende da manutenção do conteúdo da fonte.

Etapas	Registros
Amostra bruta	386.367
Sem avaliação válida	51.012
Base elegível	335.355

A amostra não garante representatividade de todos os municípios. As taxas calculadas sobre alunos são não ponderadas, salvo indicação contrária; o peso disponibilizado pela fonte foi preservado, mas não utilizado nas métricas apresentadas.

4. Preparação dos dados

Os dados foram organizados em três camadas:

Bronze: cópias das fontes consultadas, incluindo a amostra de alunos.

Silver: padronização, seleção dos registros elegíveis e integração das bases.

Gold: base analítica, conjuntos de treino, validação e teste e tabelas de contexto.

A preparação foi reconstruída neste projeto. A implementação realiza extrações em lote; não inclui streaming nem orquestração contínua.

Validações realizadas

Verificação de chaves incompletas e duplicidades.

Conferência entre classificação e proficiência.

Validação de relacionamentos muitos-para-um.

Conferência da quantidade de alunos após os cruzamentos.

Identificação de registros sem correspondência e valores ausentes.

Separação entre metas não aplicáveis e metas não localizadas.

Todos os alunos elegíveis receberam identificação territorial. Houve 18 registros sem resultado municipal, 2.234 sem resultado estadual e 126 sem indicadores do Atlas. Os alunos foram mantidos, com as ausências preservadas.

As metas municipais foram vinculadas somente à rede municipal. As metas estaduais e nacionais foram organizadas em tabelas separadas, preservando o ano da meta e a referência da fonte.

5. Análise exploratória

A exploração que orientou a modelagem utiliza somente o treino de 2023.

Distribuição da alfabetização

No treino, 58,5% dos alunos são alfabetizados e 41,5% não alfabetizados. As duas classes possuem volume relevante; a acurácia isolada não é suficiente para avaliar o modelo.

Diferenças territoriais e educacionais

A proporção de alfabetizados varia de 51,4% no Norte a 67,9% no Sul, uma diferença aproximada de 16,5 pontos percentuais na amostra de treino.

A rede estadual apresenta 61,8%, e a municipal, 58,2%. Os grupos têm volumes e contextos distintos.

A taxa passa de 49,7% no quartil de menor IDHM para 60,4% no de maior IDHM. Os quartis são definidos pelos municípios do treino e não correspondem às categorias oficiais do índice.

Relações entre os indicadores

IDHM e renda apresentam correlação de Spearman de 0,95. IDHM e analfabetismo adulto apresentam correlação de -0,90. Essa sobreposição precisa ser considerada na interpretação das variáveis.

Insight: o contexto municipal está associado ao resultado observado, mas essas associações não demonstram causalidade nem descrevem as condições individuais das famílias.

6. Modelagem supervisionada

Variáveis utilizadas

Numéricas: população, IDHM, renda per capita, analfabetismo adulto, acesso à água encanada e inadequação de água e esgoto, todos referentes a 2010.

Catégoricas: rede de ensino e UF.

Alunos da mesma rede e município compartilham os atributos utilizados. O modelo representa principalmente diferenças de contexto, com pouca informação individual.

Pré-processamento

As pipelines do scikit-learn integram:

Imputação de numéricos pela mediana, com indicador de ausência.

Tratamento de categorias ausentes.

Codificação das categorias com OneHotEncoder.

Padronização numérica para a regressão logística.

Classificador.

O pré-processamento é ajustado somente no treino. As categorias desconhecidas são tratadas pelo encoder sem interromper a previsão.

Separação dos dados

Conjunto	Ano	Alunos	Municípios
Treino	2023	122.978	3.843
Validação	2023	27.195	961
Teste	2024	185.182	5.434

Treino e validação não compartilham municípios. O teste avalia a generalização temporal para 2024, mas pode conter municípios presentes no treino. A divisão e os modelos utilizam semente 42, quando aplicável.

Algoritmos e seleção

Foram comparados DummyClassifier, regressão logística e Random Forest. Configurações adicionais e limiares de risco foram avaliados na validação, pelo F1 da classe não alfabetizado.

A configuração selecionada foi **regressão logística com $C=0,1$ e limiar de 0,35 para a probabilidade da classe 0**. O modelo permaneceu treinado apenas no treino original. Não houve novo ajuste a partir dos resultados de teste.

A seleção utiliza uma divisão fixa por município, sem validação cruzada. O resultado na validação é usado para escolha, e não como avaliação final independente.

7. Resultados no teste de 2024

Indicador	Modelo selecionado
Precisão dos alertas de não alfabetização	43,61%
Recall dos não alfabetizados	86,54%
F1 dos não alfabetizados	58,00%
Acurácia	49,45%
Acurácia balanceada	55,47%
ROC AUC de risco	0,6103
Average Precision de risco	0,5073
Alunos sinalizados	80,01%

O que esses resultados significam?

O modelo identificou 64.620 alunos não alfabetizados e deixou de identificar 10.050. Também gerou 83.553 falsos alertas e classificou corretamente 26.959 alunos alfabetizados.

O recall elevado foi acompanhado por muitos alertas: cerca de 80% dos alunos foram sinalizados. A referência que sinaliza todos alcança F1 de 57,47%, apenas 0,53 ponto percentual abaixo do modelo. A referência majoritária alcança acurácia de 59,68%, superior à do modelo, mas não identifica nenhum aluno da classe 0.

Insight: o modelo apresenta discriminação limitada. O recall de 86,54% não equivale à acurácia e não deve ser apresentado isoladamente como sucesso da solução.

8. Interpretação e aplicação estratégica

Quais variáveis contribuem para as previsões?

A importância por permutação foi calculada na validação, com cinco repetições e ROC AUC como métrica.

Variável	Queda média na ROC AUC
UF	0,13465
IDHM de 2010	0,03344
Analfabetismo adulto de 2010	0,01736
Renda per capita de 2010	0,00351

Esses valores não representam percentuais de explicação ou efeitos causais. A permutação pode romper relações entre atributos correlacionados; a importância deve ser interpretada em conjunto com a análise exploratória.

Quais municípios apresentam maior risco?

Foram agregados os escores do teste por município. A visualização considerou 311 municípios com pelo menos 100 alunos na amostra. O critério reduz a exposição de grupos pequenos, mas não garante representatividade.

O ranking descreve escores do modelo nesse recorte. Não constitui uma lista oficial de prioridade, e a média dos escores não deve ser tratada como taxa calibrada de não alfabetização.

Quais regiões apresentam resultados semelhantes?

Na descrição do treino, Sudeste e Centro-Oeste apresentam proporções próximas, de 59,2% e 58,5%. Essa proximidade em um indicador não comprova semelhança de todo o perfil educacional. Não foi realizado agrupamento multivariado de regiões.

Como os resultados se comparam às metas?

A análise retrospectiva utiliza a taxa e a meta publicadas para a rede municipal em 2024, na referência 2024 da fonte, sem substituir os resultados pela taxa da amostra.

2.788 municípios atingiram ou superaram a meta: 53,3% dos comparáveis.

2.444 municípios ficaram abaixo: 46,7% dos comparáveis.

120 municípios não tinham dados suficientes para comparação.

O denominador é de 5.232 municípios comparáveis. A tabela completa contém 5.352 registros municipais nessa referência e não deve ser confundida com a cobertura da amostra de alunos.

É possível prever o cumprimento de metas futuras?

Esta versão não valida uma previsão de metas futuras. Essa aplicação exigiria histórico adicional, informações disponíveis antes de cada avaliação e validação própria no nível municipal. As metas apoiam o acompanhamento descritivo nesta entrega.

9. Limitações e evoluções

Indicadores socioeconômicos de 2010 têm defasagem de 13 a 14 anos em relação às avaliações.

Poucas características individuais limitam a diferenciação entre alunos do mesmo contexto.

A amostra não assegura representatividade municipal, e os resultados apresentados não utilizam pesos amostrais.

A cobertura de municípios varia entre anos.

A seleção de parâmetros e limiar utiliza uma única validação; não foram estimados intervalos de confiança.

Os escores não passaram por avaliação específica de calibração.

A elevada quantidade de falsos alertas limita o uso operacional.

Como evolução, recomenda-se integrar dados mais recentes de infraestrutura escolar, frequência e trajetória de aprendizagem, respeitando a disponibilidade anterior ao resultado. Também são necessários avaliação ponderada, validações temporais adicionais e critérios de decisão alinhados à capacidade de intervenção.

10. Como executar

Ambiente recomendado

Google Colab, ambiente utilizado no desenvolvimento. O arquivo usa `google.colab` para autenticação e downloads e caminhos em `/content`. Esta versão não executa diretamente no VS Code local apenas com a instalação das bibliotecas.

Requisitos

Conta Google com acesso ao Colab.

Projeto próprio no Google Cloud com permissão para executar consultas no BigQuery e acesso às fontes públicas utilizadas.

Bibliotecas compatíveis com as versões registradas no projeto.

O BigQuery Sandbox pode ser utilizado dentro de suas limitações e cotas. Em projetos com faturamento ativo, aplicam-se as condições de cobrança do projeto. As consultas do notebook possuem limite de 1 GiB de processamento faturável por consulta.

Passo a passo

1. Abra o notebook principal no Google Colab.
2. Se necessário, instale as versões indicadas no `requirements.txt` e reinicie a sessão antes da execução.
3. Na célula de configuração, substitua `PROJECT_ID` pelo ID do seu próprio projeto. O projeto da autora não concede acesso a outros usuários.
4. Execute a célula de autenticação e conclua a autorização com a conta que possui acesso ao projeto.
5. Execute as demais células na ordem, do início ao fim.
6. Confira os registros e as métricas de referência apresentados neste relatório.
7. Salve o notebook executado e exporte os arquivos antes de encerrar a sessão.

Arquivos gerados

O diretório `/content/alfabetizacao-brasil` recebe as bases em Parquet, gráficos em PNG/SVG, tabelas em CSV e o modelo em Joblib. A pasta `/content` é temporária. A execução também disponibiliza backups em ZIP em etapas do fluxo.

Para aplicar o modelo salvo, use `predict_proba`, selecione a probabilidade da classe 0 e aplique o limiar armazenado de 0,35. Usar somente `predict()` não reproduz essa regra de decisão.

Reprodução

A execução completa no Colab foi confirmada pela autora. O notebook entregue contém 45 células de código executadas, sem erros registrados, e resultados finais compatíveis com os valores documentados. O histórico contém reexecuções e não comprova uma execução única em sessão limpa.

O ambiente original registrou Python 3.13, pandas 2.2.3 e scikit-learn 1.6.1. As versões completas devem acompanhar o repositório. Alterações nas fontes ou no ambiente podem modificar os resultados.

Conclusão

A análise identificou diferenças territoriais e associações entre alfabetização e contexto socioeconômico. A comparação com metas mostrou que 46,7% dos municípios com dados comparáveis ficaram abaixo da meta de 2024.

O modelo individual apresentou desempenho limitado, com muitos falsos alertas. A principal contribuição do projeto é uma base analítica reproduzível, acompanhada de uma avaliação transparente do que os dados permitem concluir e do que ainda precisa evoluir antes de uma aplicação operacional.

Autoria e contexto

Ana Carolina Perchak dos Santos

Projeto de análise de dados e aprendizado de máquina desenvolvido para portfólio.

Referências

Avaliação da Alfabetização — Base dos Dados

Atlas do Desenvolvimento Humano — Base dos Dados

Diretório territorial: `basedosdados.br_bd_diretorios_brasil.municipio`.

Google Colab

BigQuery Sandbox


Prevenção de erros e vazamento de dados — scikit-learn

Gráficos complementares

ALFABETIZAÇÃO NO BRASIL

Alfabetização por contexto de desenvolvimento

Faixas de IDHM municipal de 2010 • Alunos da amostra de treino de 2023




Fontes: Inep e Atlas do Desenvolvimento Humano, via Base dos Dados.

Quartis dos municípios do treino; taxas por aluno, sem ponderação. Associação não implica causalidade.

ALFABETIZAÇÃO NO BRASIL

Onde o modelo acerta e erra

Teste de 2024 • Regressão logística • Limiar de risco: 0,35




Fonte: avaliações de alfabetização do Inep, via Base dos Dados.

Contagens da amostra; percentuais calculados por classe real. Modelo e limiar definidos antes da avaliação do teste.

Quais variáveis ajudam o modelo?


Importância por permutação • Validação de 2023 • Queda na ROC AUC



Barras: queda média em 5 permutações. Hastes: desvio-padrão entre repetições, não intervalo de confiança. Importância preditiva não implica causalidade. Atributos correlacionados podem compartilhar informação.

Cumprimento das metas de alfabetização

Rede municipal • Resultado e meta de 2024 • 5.232 municípios comparáveis



Fonte: tabela de metas municipais do Inep, via Base dos Dados; referência da fonte: 2024. 120 municípios sem dados comparáveis foram excluídos dos percentuais. Cada município tem o mesmo peso.

Repositório e materiais

github.com/AnaPerchak123/alfabetizacao-brasil

Vídeo da apresentação (pasta no Drive)

Materiais e backups no Google Drive